

AKI 智能预测系统 — 测试报告

急性肾损伤机器学习预测与临床决策支持系统

报告日期：2026年07月23日

团队：白菜卷队 | 广西科技大学 | 暑期数创 2026

版本：v2.0 (基于 run_clean.py AUC 0.821 基线)

一. 程序整体概述以及核心模块拆解

1.1 程序整体逻辑

本程序为急性肾损伤（AKI）智能预测系统，基于420例心脏手术患者的围术期临床数据，构建4种机器学习模型及加权Voting集成，通过SHAP可解释性分析实现预测过程的透明化，最终部署为Streamlit Web应用，为临床医生提供可交互的个体化风险评估工具。

整体架构分为三个层次：数据层（数据加载、清洗、特征工程）、模型层（模型训练、评估、集成、可解释性）、应用层（Web预测、风险报告、医生工作台、管理仪表盘）。

1.2 核心模块拆解

数据加载与清洗 (src/data/cleaning.py): 420例原始数据 → 异常值处理 → 缺失值填补 → 数据泄漏审查
特征工程 (run_clean.py (模块3)): 84候选特征 → RF特征重要性排序 → Top35关键特征
模型训练与CV (run_clean.py (模块4)): 4模型 + Voting集成 → 50次重复分层5折CV → AUC评估
可解释性分析 (src/visualization/shap_viz.py): SHAP全局+局部解释 → 反事实What-If分析
数据治理可视化 (src/visualization/data_governance.py): 7阶段治理流程 → 特征筛选漏斗 → 质量仪表盘
消融实验 (src/models/ablation.py): 特征组增量实验 → 热力图+柱状图 → 消融对比表
交叉验证可信度 (src/models/cross_validate.py): 五折CV ROC置信带 → Bootstrap AUC分布
集成学习管线 (src/models/ensemble.py): Voting/Stacking/Weighted Avg → 网格搜索元学习器
时序风险轨迹 (src/models/temporal.py): T0→T1→T2增量建模 → 个体风险轨迹可视化
Web预测系统 (streamlit_app.py / web/app.py): 7页面系统: 预测+医生工作台+管理仪表盘+报告

二. 数据说明与数据处理方案论述

2.1 数据集概述

项目	说明
数据来源	广西某三甲医院心脏外科EHR系统
样本量	420例 心脏手术患者
原始特征数	97个临床变量
AKI发生率	29.8% (125/420)
AKI分期分布	Stage0:295 / Stage1:91 / Stage2:24 / Stage3:10
时间跨度	2019年1月 - 2023年12月
数据格式	Excel (.xlsx) 结构化存储

2.2 数据处理方案

本研究建立了系统性的七阶段数据治理管线：

- 原始数据采集 — 420例，97个变量，Excel结构化存储。
- 缺失值分析 —
以30%为阈值剔除高缺失变量（97→86），保留变量采用中位数（连续型）和众数（分类型）填补。
- 异常值检测 — 基于临床参考范围识别异常值（如Scr 20–500 μmol/L，eGFR 10–150ml/min/1.73m），人工审查确认。
- 标准化与编码 — 连续变量Z-score标准化；分类变量One-Hot编码。
- 数据泄漏审查 — 排除KDIGO诊断标准（术后48h/7d Scr/eGFR）、结局变量（住院天数/费用）、术后晚期指标（术后7d RBP）。
- 特征筛选 — 随机森林特征重要性排序，选取Top35关键特征。
- 建模数据集 — N=420，P=35的规范化数据集。

初始模型AUC >

0.99，经系统性审查发现特征中包含术后48h/7d肌酐——这正是KDIGO诊断标准本身（"用答案预测答案"）。排除泄漏特征后，纯术前特征AUC为0.74，最终版（术前+术中+ICU早期非肌酐特征）AUC为0.821。保留特征论证：所有纳入特征在入ICU即刻即可获取，预测时点具有临床可操作性。

三. 模型的挑选、增强/微调策略论述

3.1 模型选择与特点

本研究选择4种具有不同建模范式的机器学习算法，覆盖线性模型和树集成模型两大类别：

- Logistic回归 (C=0.02, L2): 线性基线模型，强正则化，高可解释性。适用于临床基线对照。CV AUC: 0.808±0.044
- RandomForest (max_depth=5, min_samples_leaf=15): Bagging集成，抗过拟合，非线性建模。CV AUC: 0.815±0.043

XGBoost (max_depth=3, reg_alpha=reg_lambda=1.0): 梯度提升, 强正则化, 内置缺失值处理。CV AUC: 0.819±0.043

ExtraTrees (max_depth=5, min_samples_leaf=15): 极端随机化分裂, 进一步降低方差。CV AUC: 0.809±0.044

3.2 :

采用加权Voting Ensemble (Soft Voting) 融合4种基模型:

权重配置: Logistic回归:2, 随机森林:2, XGBoost:1, ExtraTrees:1

最终性能: AUC 0.821±0.043 (50次重复分层5折CV), Bootstrap 95%CI [0.779, 0.865]

Voting集成比任何单一模型更稳定, 融合了线性模型的校准优势和树模型的非线性建模能力。

3.3 训练与验证策略

验证方案: 50次重复五折分层交叉验证 (Stratified 5-Fold × 10 Repeats = 250次训练-评估迭代)

正则化策略: 所有模型采用强正则化控制过拟合 (低C值、限制树深度、min_samples_leaf≥10等)

类别平衡: class_weight="balanced" + SMOTE仅在训练集内合成少数类样本

过拟合控制: 训练-测试AUC差距0.128, 在420例中等样本下处于可接受范围

四. 程序的整体优化策略

4.1 时间效率优化

模型推理: Web预测响应时间 < 2秒, 支持实时风险评估

批量评估: 支持CSV文件批量导入, 一次完成多患者预测

模型加载: 使用Streamlit @st.cache_resource缓存模型, 避免重复加载

并行训练: 使用n_jobs=-1充分利用多核CPU加速CV评估

4.2 空间/部署优化

模型序列化: 使用joblib持久化训练好的模型和标准化器, 即载即用

GitHub + Streamlit Cloud: 代码托管在GitHub, Web应用通过Streamlit Cloud自动部署

模块化设计: src/目录下各模块独立可复用, 支持灵活组合

数据治理: 七阶段管线确保数据处理的可复现性和透明性

4.3 效果对比

优化阶段	AUC效果
初始模型 (含数据泄漏)	AUC > 0.99 (不可信)
纯术前特征 (保守)	AUC 0.74
术前+术中+ICU入室	AUC 0.79
最终版 (+术后早期非肌酐)	AUC 0.821±0.043 (当前最优)

关键洞察: "一个可信的0.821, 胜过一百个泄漏的0.99。"

五. 评价指标挑选与程序效果评估

5.1 评价指标定义

指标	定义 / 评价标准
AUC-ROC	反映模型将正负样本正确排序的能力。越接近1越好
50次重复CV	50次独立分层5折交叉验证取均值±标准差。评估稳定性
Bootstrap 95%CI	1000次Bootstrap重抽样计算AUC置信区间。评估可靠性
Brier Score	预测概率与真实结局的均方误差。越小越好 (<0.25为可接受)
过拟合差距	训练AUC - 测试AUC。越小越好 (<0.15为可接受)

5.2 核心模型性能

模型	50次CV AUC ± 标准差
Logistic回归	0.808 ± 0.044
随机森林 (RF)	0.815 ± 0.043
XGBoost	0.819 ± 0.043
ExtraTrees	0.809 ± 0.044
★ Voting Ensemble	0.821 ± 0.043

5.3 过拟合检查

指标	数值 / 判断
训练AUC - 测试AUC差距	0.128
Bootstrap 95%CI	[0.779, 0.865]
Brier Score	0.152
判断	过拟合程度可控，模型泛化能力可接受

5.4 效果评估结论

Voting Ensemble以AUC 0.821±0.043的表现优于所有单一模型，在四种基模型中，XGBoost（0.819）和随机森林（0.815）是集成的主要贡献者。Bootstrap 95%CI为[0.779, 0.865]，Brier Score 0.152表明预测概率校准良好。

SHAP分析揭示术前肾功能（eGFR/Scr）、年龄、APACHE II评分和术中尿量为前四位预测因子，与临床共识一致，增强了模型的可信度。

六. 作品价值与创新性

6.1 应用价值

心脏手术后AKI发生率约30%，是增加死亡率和医疗费用的重要并发症。现有临床评分（如克利夫兰评分、STS评分）的AUC

多在0.70-0.80之间，且无法提供个体化解释。本系统AUC达0.821，配合SHAP可解释性，为临床医生提供了"不仅预测风险，更解释为什么"的决策支持工具。

6.2 创新点

数据泄漏系统性审查：
识别并排除KDIGO诊断标准、结局变量等泄漏特征，确保模型可信度。同类研究中少见如此详细的泄漏控制论述。

完整的模型可信度体系：五折CV ROC置信带 + Bootstrap AUC分布 + 消融实验 + DCA临床决策曲线 + 校准曲线 + 数据治理可视化，构建了超越常规的评估框架。

SHAP反事实解释 (What-If)：
不仅展示特征重要性，还支持"如果肌酐降低20%，风险从72%降至45%"的交互式临床推理，将可解释性推向决策支持层面。

时序风险轨迹预测：基于T0(术前)→T1(术中)→T2(ICU早期)的增量建模，模拟患者旅途中的风险动态变化。

从模型到系统的全链路闭环：
"数据治理—建模—评估—可解释—Web部署—PDF报告"的完整实践，超越仅报告性能指标的常规研究。

医生工作台+管理仪表盘：患者批量评估、AKI趋势监控、科室分布、高危预警——面向医院管理者的决策支持。

6.3

维度	传统方案 vs 本作品
预测性能	临床评分 AUC 0.70-0.80 → 本系统 Voting AUC 0.821
可解释性	无/有限 → SHAP全局+局部+反事实What-If
部署形态	静态公式/评分卡 → Streamlit Web实时交互
数据泄漏控制	少有系统性论述 → 七阶段治理+泄漏排除论证
评价体系	单一AUC → 50次CV+Bootstrap+DCA+校准+消融
用户界面	无 → 7页面系统(预测+工作台+仪表盘+报告)

七. 其他情况说明

7.1 技术栈

语言：Python 3.11 | 框架：scikit-learn, XGBoost, SHAP
可视化：Matplotlib, Seaborn | Web：Streamlit
验证：RepeatedStratifiedKFold, Bootstrap | 报告：fpdf2

7.2 局限性

样本量有限（420例），属于单中心回顾性研究，外部验证尚待开展。

EPV (Events Per Variable) = 3.6，略低于理想值（≥10），但在强正则化下模型仍稳定。

时序分析基于"伪时序"特征分组，非真正纵向随访数据。

目前未包含影像组学、基因组学等多模态数据。

多中心外部验证，提升模型泛化性能证据。

7.3

纳入更多术中动态监测数据（如实时血流动力学），实现更精细的时序建模。
开发REST API接口，支持与医院HIS/EMR系统集成。
开展前瞻性临床验证研究。

7.4

角色	负责人 / 主要职责
队长 / 技术路线 / 论文	蓝可 — 统筹、建模、优化、论文框架
数据清洗 / 特征工程	李婷、蓝可 — 数据预处理、EDA、泄漏审查
建模 / SHAP	梁日娇、蓝可 — 模型训练、评估、可解释性分析
Web开发	王若兮 — Streamlit系统开发、前后端
论文撰写	叶宇晨、蓝可 — 论文撰写、文献综述

免责声明：本系统仅供学术研究和临床参考，不作为最终诊断依据。所有临床决策应由合格医疗专业人员根据综合患者评估做出。
版权：白菜卷队 · 广西科技大学 · 暑期数创 2026 · 仅限学术用途